Thomas GOEURY — PhD
Data Scientist

525 Route de la Maurienne – 73390 Bourgneuf

(+33) 6 85 70 51 54 • thomas.goeury@protonmail.com • tgoeury.github.io/

LinkedIn

Data scientist et docteur en biologie (génomique des populations) avec plus de **10 ans d'expérience** dans la conception de pipelines d'analyses et visualisations de données, ainsi que le développement de tableaux de bord interactifs. Passionné par les solutions *data-driven*, j'ai mené à bien plusieurs projets de grande envergure: création d'un **tableau de bord en temps réel** pour le suivi de la pandémie de COVID-19 dans le canton de Genève, implémentation d'un système de **contact-tracing basé sur Neo4j** et développement d'un **algorithme d'analyse de données de séquençage génétique**.

Expérience professionelle

Université de Genève — **Genève (CH)**
Chercheur post-doctoral — *2023-2025*

- Analyses statistique des données de séquençages *next-gen* dans le cadre d'un projet de recherche international étudiant la diversité des gènes HLA (*Human Leukocyte Antigen*) au sein de 40 populations africaines.
- Utilisation d'une méthode inédite basée sur les chaînes de Markov pour analyser l'évolution du complexe majeur d'histocompatibilité (MHC) chez les primates.

Service du medecin Cantonal — **Genève (CH)**
Data Scientist, Cellule COVID-19 — *2020-2022*

- Mise en place d'un pipeline d'ETL (*Extract, Transform, Load*) et d'un dashboard R-Shiny pour visualiser en temps réel l'évolution de la pandémie de COVID-19 dans le canton de Genève. Amélioration continue de ce dashboard tout au long de la pandémie.
- Développement d'une application de contact-tracing reposant sur une base de données en graphs Neo4j, permettant la détection de nouveaux clusters de contaminations et l'étude des chaînes de contamination.
- Réalisation de rapports et visualisations des données de la pandémie soutenant les décisonnaires politiques dans leurs décisions (data-driven decisions).

Université de Genève — **Genève (CH)**
Thèse de doctorat — *2015-2020*

- Développement de l'algorithme MADaM (*Multiplexed Amplicon Data Miner*), pour analyser des données de séquençage *next-gen*, basé sur une classification non supervisée sur des données fortement biaisées; L'algorithme montre une précision de plus de 98.5%, surperformant les solutions existantes de 30%.
- Analyse des gènes HLA sous le prisme de la théorie de l'information (C. Shanon), permettant de cibler plus efficacement les régions géniques les plus informatives, réduisant ainsi les coûts des analyses de génomiques des populations.

Compétences professionelles

Compétences techniques:

- Languages informatiques: python, R, bash, SQL, neo4j
- Visualisation de données et tableaux de bord interactifs (plotly, shiny, ggplot, dash)
- NLP (*Natural Language Processing)*
- AI: AIg et LLM
- Full-stack *machine learning* et *data science* (sklearn, pandas, data.table, numpy)
- Autres: LaTeX, Git, environnement UNIX, html/css

Soft skills: Autonomie, travail en équipe, résolution de problèmes, prise de décisions, rédaction de rapports, de synthèses et de documentation

Langues

Francais: Langue maternelle

Anglais (professionel): Lu, parlé et écrit

Autres

2014 - Thèse de master, Grenoble (FR): Modélisation de l'impact du réchauffement climatique sur l'étage alpin des Andes tropicales (páramos) à l'aide des modèles de distribution d'espèce (*SDM*) et de statistiques prédictives

Loisirs: Équitation, maroquinerie (en auto-entrepreneur depuis 2023)